

Maturitní otázka číslo 11: Matematická statistika

Základní pojmy

- **Statistický soubor** je množina všech objektů, které jsou předmětem zkoumání. Musí být přesně vymezen z hlediska věcného, prostorového a časového. Počet prvků v souboru označujeme jako n . Je to konečná množina.
- **Statistická jednotka** je jednotlivý prvek statistického souboru.
- **Statistické znaky** (x) jsou vlastnosti, které u jednotek sledujeme. Dělí se na kvantitativní (vyjádřené číslem) a kvalitativní (vyjádřené slovně). Každý znak nabývá **hodnoty znaku**: $x_1, x_2, \dots, x_r$ ($r \leq n$), tyto hodnoty jsou navzájem neslučitelné a pro každou statistickou jednotku musí jedna z těchto hodnot nastat. Označení hodnoty znaku x pro statistickou jednotku i je x_i .
- **Rozsah souboru** je počet statistických jednotek ve statistickém souboru.
- **Skupinové rozdělení četností** se používá u spojitých znaků, nebo velkých souborů. Hodnoty se třídí do **intervalů**. Každý interval je pak reprezentován jeho středem.
- **Kvantily** jsou charakteristiky polohy, které dělí uspořádaný datový soubor na několik zhruba stejně početných částí. Například medián dělí statistický soubor na 2 stejné části (je to kvartil). **Tercil** rozděluje statistický soubor na třetiny, Kvartil ho rozděluje na čtvrtiny, kvintil na pětiny, decil na desetiny a percentil na setiny.

Příklad: výrok, že 90 procent účastníků závodu mělo čas pod 2 hodiny, vlastně konstatuje, že 90. percentil (nebo devátý decil) dosažených časů je 2 hodiny.

Četnosti

- **Absolutní četnost** (n_j) je počet jednotek, které mají danou hodnotu znaku x_i . Platí, že $\sum_{j=1}^r n_j = n$
- **Relativní četnost** (ν_j) je podíl absolutní četnosti k rozsahu souboru ($\nu_i = \frac{n_i}{n}$) a platí, že: $\sum_{j=1}^r \nu_j = 1$
- **Kumulativní četnost** je postupný součet četností (absolutních či relativních) seřazených hodnot.

Grafické znázornění rozdělení četností

Existuje více způsobů rozdělení četností hodnot znaku x .

Prvním z nich je tabulka, kde v prvním řádku jsou hodnoty znaku x a v druhém odpovídající četnosti.

Druhým způsobem je spojnicový diagram. To je lomená čára spojující body, jejichž první souřadnice jsou hodnoty znaku x a druhé souřadnice jsou odpovídající četnosti (pouze pro kvantitativní znaky).

Třetí způsob je sloupkový diagram, kde základny sloupků znázorňují jednotlivé hodnoty znaku x , popřípadě intervaly o nichž jsou tyto hodnoty sdruženy. Výšky sloupků znázorňují odpovídající četnosti (zejména pro kvantitativní znaky).

Čtvrtý je kruhový diagram, kde jednotlivé hodnoty znaku x jsou znázorňeny kruhovými výsečemi, jejichž středové úhly jsou přímo úměrné odpovídajícím četnostem. (zejména pro kvalitativní znaky)

Charakteristiky polohy kvantitativního znaku

- **Aritmetický průměr** ($\bar{x}$) je citlivý na extrémní hodnoty, jeho vzorec je
$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{j=1}^J x_j n_j$$
- **Vážený aritmetický průměr** ($\bar{x}$) se používá, pokud mají hodnoty různou váhu (známky na bakalářích), máme-li soubor hodnot a k nim odpovídající váhy $W = \{w_1, \dots, w_n\}$, pak je vážený průměr dán vzorcem

$$\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i} = \frac{w_1 x_1 + w_2 x_2 + \dots + w_n x_n}{w_1 + w_2 + \dots + w_n}$$

Pokud jsou všechny váhy stejné, pak je vážený průměr totožný s aritmetickým průměrem. Vážený průměr lze použít pro výpočet průměrné rychlosti (pokud je zadán čas)

Příklad: Auto jelo 1 hodinu rychlostí 50 km/h a půl hodiny 80 km/h, jakou mělo auto průměrnou rychlost?

Řešení: Čas je v tomto případě váha znaku a rychlost je hodnota znaku, takže dosadím do vzorce:

$$\bar{x} = \frac{1 \cdot 50 + 0.5 \cdot 80}{1 + 0.5} = 60 \text{ kmh}^{-1}$$

- **Geometrický průměr** se používá pro míry růstu (inlace, rozmnožování bakterií ...), jeho vzorec je:

$$\bar{x}_g = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n} = \sqrt[n]{\prod_{i=1}^n x_i}$$

Existuje i jeho vážená varianta, funguje podobně jako ostatní varinaty váženého průměru.

- **Harmonický průměr** používáme pro data s převrácenými hodnotami, nebo poměry (rychlost, čas, hustota), vzorec je:

$$\overline{x_h} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Použijeme ho pro výpočet průměrné rychlosti na úsecích stejné délky.

Příklad: Vypočtete průměrnou rychlost auta, kterým jsme jeli na výlet. Cestou tam byla průměrná rychlost 80 km/h a cestou zpět jsme měli průměrnou rychlost 48 km/h.

Řešení: Protože se jedná o stejné vzdálenosti, použijeme harmonický průměr. Po dosažení do vzorce to tedy bude:

$$\overline{x_h} = \frac{2}{\frac{1}{80} + \frac{1}{48}} = 60 km/h$$

Kdyby nebyla vzdálenost stejná, ale auto by jelo 80 km/h 2 hodiny a 48 km/h jen jednu hodinu, dosazená by vypadalo následovně:

$$\overline{x_h} = \frac{3}{\frac{2}{80} + \frac{1}{48}} \doteq 65,5 km/h$$

Toto je vážená varianta harmonického průměru.

- **Modus** ($Mod(x)$) je nejčastější hodnota v souboru
- **Medián** ($Med(x)$) Je prostřední hodnota v uspořádaném souboru. Pokud je n sudé, je to průměr dvou prostředních hodnot. Není citlivý na extrémní výkyvy.

Charakteristiky variability

Dva soubory mohou mít stejný průměr, ale úplně jiný rozptyl dat (např. známky 3,3,3 a 1,3,5)

Rozptyl(s_x^2) je průměr čtverců odchylek jednotlivých hodnot od aritmetického průměru. Vzorec je:

$$s_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Odmocninou z rozptylu je **směrodatná odchylka**(s_x), má stejnou jednotku jako měřený znak. To usnadňuje interpretaci. Ukazuje jak moc jsou data rozptýlená kolem průměru.

Dále existuje **variační koeficient** (v_x), který je poměrem směrodatné odchylky k průměru, často se vzjadřuje v procentech. Slouží k porovnání variability dvou souborů s různými jednotkami. Má smysl jen tehdy, nabývá-li znak x pouze nezáporných hodnot.

$$v_x = \frac{s_x}{\bar{x}}$$

Korelace

Korelace se označuje **korelačním koeficientem** r , který nabývá hodnot $\langle -1, 1 \rangle$. Pokud se $r = 1$ pak jde o přímou závislost, body leží přesně na roustoucí přímce. Pokud je $r = -1$, pak jde o nepřímou závislost a body přesně leží na klesající přímce. Pokud $r = 0$, pak je korelace nulová a body jsou rozptýleny náhodně. Pokud je $|r| < 0.3$ pak jde o slabou korelaci. Pokud je $0.3 \leq |r| < 0.7$, pak je korelace střední a pokud $0.7 \leq |r|$, pak je korelace silná. Vzorec pro korelaci je následující, pokud předpokládáme, že vyšetřujeme uspořádanou dvojici kvantitativních znaků (x, y)

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{s_x \cdot s_y}$$